

Rapport SAE

Estimation de la population d'une région par sondage

Région : Pays de la Loire

BUT Science des Données – Statistique Inférentielle | 2025–2026

Introduction

L'objectif de cette SAE est de comprendre et d'appréhender l'incertitude liée à l'estimation d'un paramètre de population à partir d'un échantillon. Ici, le paramètre d'intérêt est le total T de la population d'une région française : les Pays de la Loire.

Le travail se divise en deux grandes parties :

- Partie 1 : Estimation du nombre total d'habitants de la région à l'aide de deux méthodes de sondage : l'échantillonnage aléatoire simple (SAS) et l'échantillonnage stratifié.
- Partie 2 : Analyse de données d'enquête sur la pratique sportive d'étudiants, via des tests d'indépendance du khi-deux et le calcul du V de Cramer.

L'ensemble du travail a été réalisé sous R, en utilisant les packages `readxl`, `sampling` et `openxlsx`.

Partie 1 : Estimation du nombre d'habitants des Pays de la Loire

Partie 1.1 : Échantillonnage aléatoire simple

1. Filtrage des données

Les données ont été chargées depuis le fichier Excel `population_francaise_communesxl.xlsx`. On filtre pour ne conserver que les communes de la région Pays de la Loire, et on sélectionne les colonnes Code département, Commune et Population totale.

```
library(readxl)
library(sampling)
donnees <- read_excel("population_francaise_communesxl.xlsx", sheet="Communes")
donnees <- donnees[donnees$`Nom de la région`=="Pays de la Loire",]
donnees <- donnees[, c("Code département", "Commune", "Population totale")]
head(donnees)
```

2. Population U

L'ensemble de la population U est composé des communes des Pays de la Loire.

Nombre total de communes N : 1 235

```
U <- donnees$Commune N <- length(U) # N = 1235
```

3. Nombre total exact d'habitants

T = 3 922 846 habitants (somme de la variable Population.totale)

```
T <- sum(donnees$`Population totale`) # T = 3 922 846
```

4. Tirage aléatoire simple (n = 100)

Un échantillon E de 100 communes est tiré au hasard sans remise depuis U.

```
n <- 100 E <- sample(U, n)
```

5. Table donnees1

On crée une table contenant les communes tirées avec leur département et leur population totale.

```
donnees1 <- donnees[donnees$Commune %in% E, ] head(donnees1)
```

6. Moyenne et intervalle de confiance à 95% pour la moyenne

On calcule la moyenne de la population dans l'échantillon, puis un IDC à 95 % via le test t de Student (adapté aux petits échantillons).

```
xbar <- mean(donnees1$`Population totale`) idcmoy <- t.test(donnees1$`Population  
totale`)$conf.int
```

Moyenne de l'échantillon : $\bar{x} = 2\,844,03$ habitants

IDC 95% pour la moyenne : [1 525,15 ; 4 162,91]

L'intervalle est large, ce qui traduit une forte hétérogénéité de taille entre communes.

7. Estimation de T et IDC pour T

On estime le total T en multipliant la moyenne par le nombre total de communes N.

```
T_est <- N * xbar  
idcT <- idcmoy * N marge <- (idcT[2] - idcT[1]) / 2
```

T_est = $1\,235 \times 2\,844,03 = 3\,512\,377$

IDC pour T : [1 883 566 ; 5 141 188]

Marge d'erreur : 1 628 811

La marge d'erreur représente environ 41 % de la vraie valeur T, ce qui indique une précision médiocre pour ce tirage. Ce résultat illustre le risque du SAS sur une population très hétérogène.

8. Reproduction 10 fois

On répète le processus 10 fois (seed=42 pour reproductibilité). Les résultats sont stockés dans un tableau Excel et illustrés par un graphique en barres.

```
set.seed(42)
for (i in 1:10) {
  E_i <- sample(U, n)
  donnees1_i <- donnees[donnees$Commune %in% E_i, ]
  xbar_i <- mean(donnees1_i$`Population totale`)
  idcmoy_i <- t.test(donnees1_i$`Population totale`)$conf.int
  T_est_i <- N * xbar_i
  idcT_i <- idcmoy_i * N
  marge_i <- (idcT_i[2] - idcT_i[1]) / 2 }
```

Tirage	T (réel)	T_est	IDC inf	IDC sup	Marge d'erreur
1	3 922 846	4 971 628	2 860 376	7 082 881	2 111 252
2	3 922 846	2 907 462	1 564 530	4 250 394	1 342 932
3	3 922 846	2 712 579	2 046 727	3 378 430	665 851
4	3 922 846	3 538 226	1 966 665	5 109 786	1 571 560
5	3 922 846	3 287 422	2 286 295	4 288 549	1 001 127
6	3 922 846	4 295 738	2 536 590	6 054 886	1 759 148
7	3 922 846	4 068 843	2 402 978	5 734 709	1 665 865
8	3 922 846	4 322 204	2 872 218	5 772 189	1 449 985
9	3 922 846	7 724 060	-253 521	15 701 642	7 977 581
10	3 922 846	7 962 181	2 556 186	13 368 176	5 405 995

9. Conclusion – Échantillonnage aléatoire simple

Les résultats montrent une très forte variabilité selon les tirages. On observe des estimations allant de 2 712 579 à 7 962 181 pour une vraie valeur de 3 922 846. Les tirages 9 et 10 produisent des intervalles de confiance extrêmement larges, l'un d'eux ayant même une borne inférieure négative.

Cette instabilité s'explique par l'hétérogénéité marquée des communes des Pays de la Loire : des villages de quelques habitants coexistent avec des grandes villes (Nantes : 325 857 habitants). Un tirage fortement biaisé vers les petites ou les grandes communes peut donner des résultats très différents de la réalité.

L'échantillonnage aléatoire simple ne garantit donc pas une bonne représentativité lorsque la population est très hétérogène.

Partie 1.2 : Échantillonnage aléatoire stratifié

1. Création des strates

On crée 4 strates par les quartiles (quantiles à 0 %, 25 %, 50 %, 75 %, 100 %) de la variable Population.totale. Chaque strate regroupe ainsi un quart des communes, du moins peuplé au plus peuplé.

```
quantiles <- quantile(donnees$`Population totale`, probs=c(0,0.25,0.50,0.75,1))
donnees$Strate <- cut(donnees$`Population totale`,
```

```
breaks=quantiles, labels=c(1,2,3,4),
include.lowest=TRUE)
```

Bornes des strates :

- Strate 1 : [11 ; 525]
- Strate 2 : [525 ; 1 173]
- Strate 3 : [1 173 ; 2 719]
- Strate 4 : [2 719 ; 325 857]

2. Table datastrate

On crée la table datastrate avec les colonnes Code département, Commune, Population totale et Strate.

```
datastrate <- donnees[, c("Code département", "Commune", "Population totale", "Strate")]
head(datastrate)
```

3. Tirage stratifié (n = 100, effectifs proportionnels)

Les 4 strates ont des effectifs quasi égaux (≈ 309 communes chacune). Avec une allocation proportionnelle, on tire $nh = 25$ communes par strate, soit $n = 100$ au total.

```
Nh <- table(data$Strate)
gh <- Nh / N
nh <- round(c(n*Nh[1]/N, n*Nh[2]/N, n*Nh[3]/N, n*Nh[4]/N))
fh <- nh / Nh
st <- strata(data, stratanames=c("Strate"), size=nh, method="srswr") data1 <-
getdata(data, st)
```

Effectifs des strates (Nh) : 309, 309, 308, 309

Taille de chaque sous-échantillon (nh) : 25, 25, 25, 25

Taux de sondage (fh) : $\approx 0,081$ dans chaque strate

4. Sous-échantillons et statistiques par strate

```
ech1 <- data1[data1$Strate==1,] ; m1 <- mean(ech1$`Population totale`)
ech2 <- data1[data1$Strate==2,] ; m2 <- mean(ech2$`Population totale`)
ech3 <- data1[data1$Strate==3,] ; m3 <- mean(ech3$`Population totale`)
ech4 <- data1[data1$Strate==4,] ; m4 <- mean(ech4$`Population totale`) var1 <-
var(ech1$`Population totale`) ; ...
```

Strate	Nh	nh	Moyenne (mh)	Variance (varh)
1	309	25	332	18 204
2	309	25	806	46 863
3	308	25	1 916	145 092
4	309	25	12 683	944 842 538

5. Moyenne stratifiée et IDC

La moyenne stratifiée est la moyenne pondérée par les poids de strates $gh = Nh/N$.

```
xbarst <- (Nh[1]*m1 + Nh[2]*m2 + Nh[3]*m3 + Nh[4]*m4) / N
varxbarst <- sum( (gh^2) * (1 - fh) * c(var1,var2,var3,var4) / nh )
binf <- xbarst - qnorm(0.975) * sqrt(varxbarst) bsup <- xbarst + qnorm(0.975) *
sqrt(varxbarst)
```

Xstrat = 3 936,16 habitants par commune

6. Estimation de Tstr et IDC pour T

```
Tstr <- N * xbarst
idcT <- c(idcmoy[1]*N, idcmoy[2]*N) marge <- (idcT[2] - idcT[1]) / 2
```

Tstr = 1 235 × 3 936,16 = 4 861 163

IDC pour Tstr : [1 291 294 ; 8 431 032]

Marge d'erreur : 3 569 869

Pour cet unique tirage, la marge d'erreur reste large, signe que la strate 4 (grandes villes) présente une variance considérable. Les simulations répétées permettront de mieux évaluer la méthode.

7. Reproduction 10 fois

Tirage	T (réel)	T_est	IDC inf	IDC sup	Marge d'erreur
1	3 922 846	3 565 719	2 292 131	4 839 306	1 273 588
2	3 922 846	3 513 515	1 878 199	5 148 831	1 635 316
3	3 922 846	4 523 076	3 019 641	6 026 511	1 503 435
4	3 922 846	2 762 346	2 364 805	3 159 887	397 541
5	3 922 846	4 881 564	2 854 895	6 908 233	2 026 669
6	3 922 846	3 215 319	2 006 882	4 423 757	1 208 438
7	3 922 846	3 318 256	2 735 047	3 901 465	583 209
8	3 922 846	3 273 969	2 416 820	4 131 119	857 149
9	3 922 846	6 850 210	-590 596	14 291 017	7 440 806
10	3 922 846	3 641 006	2 371 137	4 910 874	1 269 869

8. Améliorations proposées

Pour réduire encore la variabilité, plusieurs pistes sont envisageables :

- Augmenter le nombre de strates (5 ou 6) afin de mieux capturer la distribution asymétrique de la population.
- Stratifier par département (44, 49, 53, 72, 85) pour exploiter une variable auxiliaire géographiquement significative.
- Utiliser une allocation optimale (Neyman) qui attribuerait plus d'observations aux strates à forte variance, notamment la strate 4.
- Appliquer un sondage à probabilités inégales (PPS) où les grandes communes seraient tirées avec une probabilité proportionnelle à leur taille.

9. Conclusion comparative

La comparaison des deux méthodes est instructive. Sur les 10 tirages SAS, on observe des marges d'erreur pouvant dépasser 7 millions, avec des intervalles très larges et parfois de borne inférieure négative (tirage 9). Pour le sondage stratifié, 8 tirages sur 10 ont des marges inférieures à 2 millions, soit une amélioration sensible.

Cependant, la strate 4 reste problématique : sa variance interne est extrêmement élevée (présence de Nantes qui représente à elle seule 8 % de la population régionale). Un ou deux tirages peuvent encore donner des résultats instables. C'est pourquoi l'allocation de Neyman ou un PPS seraient plus adaptés.

10. Conclusion générale – Partie 1

Cette première partie a permis de comprendre concrètement le rôle des intervalles de confiance dans la traduction de l'incertitude d'une estimation. Le SAS, simple à mettre en œuvre, souffre de la forte hétérogénéité des communes. Le sondage stratifié améliore la précision en regroupant des communes de taille similaire, mais reste sensible à la variance de la strate des grandes villes. Pour aller plus loin, une allocation optimale ou un sondage à probabilités inégales seraient nécessaires.

Partie 2 : Traitement de données d'enquête – Pratique sportive étudiante

1. Importation des données

```
df <- read_excel("EnqueteSportEtudiant2024.xlsx")
```

2. Description du jeu de données

```
head(df) str(df)
```

La table contient 375 individus (étudiants) et 76 variables. Les individus sont des étudiants ayant répondu à l'enquête. Les variables couvrent :

- Des variables sociodémographiques : sexe, département, logement, bourse, alternant.
- Des variables comportementales : sport (pratique du sport : Oui/Non), fumer, alimentation.
- Des variables académiques : niveau (BUT1, BUT2, BUT3, Licence Pro).
- Des variables d'opinion sur l'alimentation, la santé, la réussite, etc.

Les variables d'intérêt pour notre analyse sont toutes qualitatives (nominales ou ordinales).

3. Tableaux croisés de la variable « sport »

On construit les tableaux croisés entre la variable sport et 7 variables qualitatives.

```
TCD_Sexe <- table(df$sport, df$sexe)
TCD_niveau <- table(df$sport, df$niveau)
TCD_bourse <- table(df$sport, df$bourse)
TCD_Alternant <- table(df$sport, df$alternant)
TCD_Fumeur <- table(df$sport, df$fumer)
TCD_Logement <- table(df$sport, df$logement)
TCD_Alimentation <- table(df$sport, df$alimentation)
```

Tableau croisé sport × sexe :

Sport \ Sexe	Un homme	Une femme	Total
Non	48	43	91
Oui	209	74	283
Total	257	117	374

Tableau croisé sport × alimentation :

Sport \ Alimentation	Non	Oui	Total
Non	46	45	91
Oui	81	202	283
Total	127	247	374

4. Tests du khi-deux

Pour chaque variable, on effectue un test d'indépendance du khi-deux (H_0 : sport et la variable sont indépendants).

```
khideux_sexe      <- chisq.test(TCD_Sexe)
khideux_niveau    <- chisq.test(TCD_niveau)
khideux_Alternant <- chisq.test(TCD_Alternant)
khideux_bourse    <- chisq.test(TCD_bourse)
khideux_Fumeur    <- chisq.test(TCD_Fumeur)
khideux_Logement  <- chisq.test(TCD_Logement) khideux_Alimentation <-
chisq.test(TCD_Alimentation)
```

Variable	χ^2	p-valeur	Résultat ($\alpha=5\%$)
Sexe	13,30	0,0003	✓ Significatif
Niveau	8,14	0,0431	✓ Significatif
Alternant	5,44	0,0197	✓ Significatif
Alimentation	13,80	0,0002	✓ Significatif
Bourse	1,88	0,1702	X Non significatif
Fumer	0,38	0,5373	X Non significatif
Logement	2,51	0,2849	X Non significatif

On identifie 4 variables significativement liées à la pratique du sport : le sexe, le niveau d'études, le statut en alternance et les habitudes alimentaires.

5. V de Cramer pour les tests significatifs

Pour quantifier l'intensité de la liaison, on calcule le V de Cramer. Rappelons la formule :

$V = \sqrt{(\chi^2 / (n \times \min(p-1, q-1)))}$ où p = nb lignes, q = nb colonnes, n = taille totale

```
n <- dim(df)[1]
V_Sexe <- sqrt(khideux_sexe$statistic / (n * min(nrow(TCD_Sexe)-1, ncol(TCD_Sexe)-1))) # Répéter pour chaque variable significative...
```

Variable	χ^2	p-valeur	V de Cramer	Intensité
Alimentation	13,80	0,0002	0,192	Faible–Modérée ★
Sexe	13,30	0,0003	0,188	Faible–Modérée
Niveau	8,14	0,0431	0,147	Faible
Alternant	5,44	0,0197	0,120	Faible

★ Liaison la plus forte : sport × alimentation ($V = 0,192$)

Commentaires et conclusion générale

Les résultats des tests et des V de Cramer permettent de tirer plusieurs enseignements :

Liaisons significatives :

- Sport $\times$ Alimentation ($V = 0,192$) : c'est la liaison la plus forte. Les étudiants qui ont de bonnes habitudes alimentaires pratiquent davantage le sport, ce qui suggère un comportement global « mode de vie sain ».
- Sport $\times$ Sexe ($V = 0,188$) : les hommes pratiquent significativement plus le sport que les femmes (209 oui contre 74 pour les femmes). La liaison est quasi aussi forte que celle avec l'alimentation.
- Sport $\times$ Niveau ($V = 0,147$) : les étudiants de Licence Pro pratiquent plus le sport (83 % d'entre eux déclarent « Oui »), peut-être car ils sont plus âgés et ont plus d'autonomie.
- Sport $\times$ Alternant ($V = 0,120$) : les alternants pratiquent davantage le sport, possiblement car leur emploi du temps leur laisse des plages de temps libre différentes.

Liaisons non significatives :

- Bourse, Fumer, Logement : ces variables ne montrent pas de lien significatif avec la pratique sportive. Le fait d'être boursier ou de fumer ne prédit pas la pratique du sport dans cet échantillon.

En conclusion, les facteurs les plus associés à la pratique du sport chez les étudiants sont les habitudes alimentaires et le sexe. Les intensités de liaison restent cependant faibles à modérées ($V < 0,20$), ce qui signifie qu'aucune variable à elle seule n'explique pleinement la pratique sportive. Une analyse multivariée (régression logistique, analyse factorielle) permettrait de combiner ces facteurs et d'obtenir une image plus complète.

Conclusion générale

Cette SAE a permis d'aborder deux grandes thématiques de la statistique inférentielle :

- L'estimation par intervalle de confiance, en comparant le sondage aléatoire simple et le sondage stratifié. Le sondage stratifié s'avère nettement plus précis dès lors que la population est hétérogène, comme c'est le cas pour les communes des Pays de la Loire.
- Les tests d'indépendance (khi-deux) et la mesure d'association (V de Cramer), qui permettent d'identifier et de quantifier des liens entre variables qualitatives dans des données d'enquête.

Les principaux apprentissages sont :

- La nécessité de comprendre la structure de la population avant de choisir un plan de sondage.
- L'importance de l'intervalle de confiance pour quantifier l'incertitude — une estimation sans IC est incomplète.
- La distinction entre significativité statistique (p-valeur) et intensité de liaison (V de Cramer) : un test peut être significatif sans que la liaison soit forte.

Code R Partie 1.1

```
library(readxl)
library(sampling)
# Charger les données à partir d'un fichier excel
donnees <- read_excel("population_francaise_communesxl.xlsx", sheet ="Communes")

# Filtrer les données pour ne garder que les communes de la région Pays de la Loire
donnees <- donnees[donnees$`Nom de la région`=="Pays de la Loire",]

# Sélectionner seulement les colonnes nécessaires : Code du département, Commune, Population totale
donnees<- donnees[, c("Code département", "Commune","Population totale")]
head(donnees)

#exo 2
# Variable U qui contient les noms des communes
U <- donnees$Commune

# Nombre total de communes dans U
N <- length(U)

#exo 3
# Calcul du nombre total d'habitants du Pays de la Loire
T<- sum(donnees$`Population totale`)

#exo 4
# Tirage aléatoire simple pour obtenir un échantillon de taille n=100
n<- 100
E<-sample(U,n)

#exo 5
# Extraire les données correspondant à l'échantillon sélectionné
donnees1<- donnees[donnees$Commune %in% E, ]
head(donnees1)

#exo 6
# Calcul de la moyenne de la population totale dans l'échantillon
xbar <- mean(donnees1$`Population totale`)

# Calcul de l'intervalle de confiance pour la moyenne de la population
idcmoy <- t.test(donnees1$`Population totale`)$conf.int

#exo 7
# Estimation du total d'habitants dans toute la région à partir de la moyenne de l'échantillon
T_Test<- N*xbar
T_Test

# Estimation de l'intervalle de confiance pour le total d'habitants
idcT <- idcmoy*N
idcT
```

```
# Calcul de la marge d'erreur pour l'intervalle de confiance du total
marge <- (idcT[2] - idcT[1]) / 2
```

```
#exo 8
```

```
library(openxlsx)
```

```
# --- Question 8 : répéter 10 fois le SAS ---
```

```
nb_simul <- 10
```

```
resultats_sas <- data.frame(
  Simulation      = 1:nb_simul,
  Population_reelle = numeric(nb_simul),
  Population_estimee = numeric(nb_simul),
  IDC_inf         = numeric(nb_simul),
  IDC_sup         = numeric(nb_simul),
  Marge_erreur    = numeric(nb_simul)
)
```

```
set.seed(42) # pour reproductibilité (optionnel)
```

```
for (i in 1:nb_simul) {
  E_i <- sample(U, n)
  donnees1_i <- donnees[donnees$Commune %in% E_i, ]
```

```
  xbar_i <- mean(donnees1_i$`Population totale`)
  idcmoy_i <- t.test(donnees1_i$`Population totale`)$conf.int
```

```
  T_est_i <- N * xbar_i
  idcT_i <- idcmoy_i * N
  marge_i <- (idcT_i[2] - idcT_i[1]) / 2
```

```
  resultats_sas[i, "Population_reelle"] <- T
  resultats_sas[i, "Population_estimee"] <- T_est_i
  resultats_sas[i, "IDC_inf"] <- idcT_i[1]
  resultats_sas[i, "IDC_sup"] <- idcT_i[2]
  resultats_sas[i, "Marge_erreur"] <- marge_i
}
```

```
print(resultats_sas)
```

```
# Graphique résumé (sans les IDC)
```

```
plot(1:nb_simul, resultats_sas$Population_estimee,
     type = "b", col = "blue", pch = 16,
     ylim = range(c(resultats_sas$Population_estimee, T) * c(0.95, 1.05)),
     xlab = "Simulation", ylab = "Population",
     main = "Estimations vs Population réelle")
abline(h = T, col = "red", lty = 2, lwd = 2)
legend("topright", legend = c("Estimé", "Réel"),
      col = c("blue", "red"), lty = c(1, 2), pch = c(16, NA))
```

```
# Export Excel
wb <- createWorkbook()
addWorksheet(wb, "SAS")
writeData(wb, "SAS", resultats_sas)
saveWorkbook(wb, "resultats_sas.xlsx", overwrite = TRUE)
```

#exo 9

#Observe que les 10 estimations oscillent autour de la vraie valeur T, mais avec des marges d'erreur importantes. Le SAS ne tient pas compte de l'hétérogénéité des communes (certaines très peuplées, d'autres très petites), ce qui crée une forte variabilité d'un tirage à l'autre.

Code R Partie 1.2

#exo 1

```
# Calculer les quantiles de la variable Population totale
quantiles <- quantile(donnees$`Population totale`, probs = c(0, 0.25, 0.50, 0.75, 1))
quantiles
# Définir les strates en fonction des déciles de la population
donnees$Strate <- cut(donnees$`Population totale`,
                     breaks = quantiles,
                     labels = c(1, 2, 3, 4),
                     include.lowest = TRUE)
```

#exo 2

```
datastrate <- donnees[, c("Code département", "Commune", "Population totale", "Strate")]
head(datastrate)
```

#exo 3

```
# Trier les données par strate
data <- datastrate[order(datastrate$Strate),]
head(data)
# Calculer l'effectif de chaque strate
Nh <- table(data$Strate)
N<-sum(Nh)
# Calcul des poids des strates (proportions de chaque strate dans la population totale)
gh <- Nh / N
# Tirage aléatoire stratifié pour un échantillon de taille n=100
n <- 100
nh <- round(c(n * Nh[1] / N, n*Nh[2] / N, n*Nh[3] / N, n*Nh[4] / N))
nh
# Calcul du taux de sondage dans chaque strate
fh <- nh / Nh
fh
# Effectuer un tirage aléatoire simple sans remise dans chaque strate
st <- strata(data, stratanames = c("Strate"), size = nh, method = "srswr")
# Extraire les données correspondant à l'échantillon stratifié
data1 <- getdata(data, st)
head(data1)
```

#exo 4

```
# Diviser l'échantillon stratifié par strate
```

```
ech1 <- data1[data1$Strate == 1, ]
ech2 <- data1[data1$Strate == 2, ]
ech3 <- data1[data1$Strate == 3, ]
ech4 <- data1[data1$Strate == 4, ]
# Calcul de la moyenne de la population totale dans chaque sous-échantillon
m1 <- mean(ech1$`Population totale`)
m2 <- mean(ech2$`Population totale`)
m3 <- mean(ech3$`Population totale`)
m4 <- mean(ech4$`Population totale`)
# Calcul de la variance de la population totale dans chaque sous-échantillon
var1 <- var(ech1$`Population totale`)
var2 <- var(ech2$`Population totale`)
var3 <- var(ech3$`Population totale`)
var4 <- var(ech4$`Population totale`)
```

#exo 5

```
# Calcul de la moyenne des quatre sous-échantillons
xbarst <- (Nh[1] * m1 + Nh[2] * m2 + Nh[3] * m3 + Nh[4] * m4) / N
# Estimation de la variance de la moyenne stratifiée
varxbarst = ((gh[1])^2) * (1 - fh[1]) * var1 / nh[1] +
  ((gh[2])^2) * (1 - fh[2]) * var2 / nh[2] +
  ((gh[3])^2) * (1 - fh[3]) * var3 / nh[3] +
  ((gh[4])^2) * (1 - fh[4]) * var4 / nh[4]
# Calcul de l'intervalle de confiance pour la moyenne stratifiée à 95%
alpha <- 0.05
binf <- xbarst - qnorm(1-alpha / 2) * sqrt(varxbarst)
bsup <- xbarst + qnorm(1-alpha / 2) * sqrt(varxbarst)
idcmoy <- c(binf,bsup)
```

#exo 6

```
# Estimation du total d'habitants pour toute la région par la moyenne stratifiée
Tstr <- N * xbarst
Tstr
# Estimation de l'intervalle de confiance pour le total d'habitants
binf <- idcmoy[1] * N
bsup <- idcmoy[2] * N
idcT <- c(binf,bsup)
idcT
# Calcul de la marge d'erreur pour l'intervalle de confiance du total
marge <- (idcT[2] - idcT[1]) / 2
```

#exo 7

```
resultats_strat <- data.frame(
  Simulation      = 1:nb_simul,
  Population_reelle = numeric(nb_simul),
  Population_estimee = numeric(nb_simul),
  IDC_inf         = numeric(nb_simul),
  IDC_sup         = numeric(nb_simul),
  Marge_erreur    = numeric(nb_simul)
)
```

```

for (i in 1:nb_simul) {
  st_i <- strata(data, stratanames = c("Strate"), size = nh, method = "srswr")
  data1_i <- getdata(data, st_i)

  ech_i <- split(data1_i, data1_i$Strate)

  mh_i <- sapply(ech_i, function(x) mean(x$`Population totale`))
  varh_i <- sapply(ech_i, function(x) var(x$`Population totale`))

  xbarst_i <- sum(gh * mh_i)
  varxbarst_i <- sum(gh^2 * (1 - fh) * varh_i / nh)

  binf_i <- xbarst_i - qnorm(0.975) * sqrt(varxbarst_i)
  bsup_i <- xbarst_i + qnorm(0.975) * sqrt(varxbarst_i)

  Tstr_i <- N * xbarst_i
  idcT_i <- c(binf_i * N, bsup_i * N)
  marge_i <- (idcT_i[2] - idcT_i[1]) / 2

  resultats_strat[i, "Population_reelle"] <- T
  resultats_strat[i, "Population_estimee"] <- Tstr_i
  resultats_strat[i, "IDC_inf"] <- idcT_i[1]
  resultats_strat[i, "IDC_sup"] <- idcT_i[2]
  resultats_strat[i, "Marge_erreur"] <- marge_i
}

print(resultats_strat)

# Graphique
plot(1:nb_simul, resultats_strat$Population_estimee,
     type = "b", col = "darkgreen", pch = 16,
     ylim = range(c(resultats_strat$Population_estimee, T) * c(0.95, 1.05)),
     xlab = "Simulation", ylab = "Population",
     main = "Stratifié : Estimations vs Population réelle")
abline(h = T, col = "red", lty = 2, lwd = 2)
legend("topright", legend = c("Estimé (strat.)", "Réal"),
      col = c("darkgreen", "red"), lty = c(1, 2), pch = c(16, NA))

# Ajout dans le même fichier Excel
addWorksheet(wb, "Stratifie")
writeData(wb, "Stratifie", resultats_strat)
saveWorkbook(wb, "resultats_sas.xlsx", overwrite = TRUE)

#exo 9
# Les estimations sont en général plus proches de T et les marges d'erreur plus faibles. En regroupant les communes
par taille de population, on réduit la variance au sein de chaque strate et on améliore la précision. Compare les colonnes
Marge_erreur des deux tableaux Excel pour l'illustrer chiffres à l'appui.

#exo 10

```

#L'IDC quantifie l'incertitude : même avec $n=100$, on ne connaît pas T exactement.

#Le SAS est simple à mettre en œuvre mais peu efficace quand la population est très hétérogène.

#Le sondage stratifié améliore la précision en exploitant une information auxiliaire connue à l'avance (la taille de la commune).

#Pour aller plus loin, on pourrait augmenter le nombre de strates, ou utiliser un sondage à probabilités inégales (PPS) où les grandes communes seraient tirées avec une probabilité plus forte.

Code R Partie 2

#1- Importer la table EnqueteSportEtudiant2024.csv dans R

```
df <- read_excel("EnqueteSportEtudiant2024.xlsx")
```

#exo 2

Affichage des 6 premières lignes

```
head(df)
```

```
str(df)
```

#exo 3

Exemple 1 : sport x sexe

```
TCD_Sexe <- table(df$sport, df$sexe)
```

Exemple 2 : sport x niveau

```
TCD_niveau <- table(df$sport, df$niveau)
```

Exemple 3 : sport x bourse

```
TCD_bourse <- table(df$sport, df$bourse)
```

Exemple 4 : sport x alternant

```
TCD_Alternant <- table(df$sport, df$alternant)
```

Exemple 5 : sport x fumer

```
TCD_Fumeur <- table(df$sport, df$fumeur)
```

Exemple 6 : sport x logement

```
TCD_Logement <- table(df$sport, df$logement)
```

Exemple 7 : sport x alimentation

```
TCD_Alimentation <- table(df$sport, df$alimentation)
```

#exo 4

Test du khi2

```
khideux_sexe <- chisq.test(TCD_Sexe)
```

```
khideux_sexe
```

```
khideux_Alternant <- chisq.test(TCD_Alternant)
```

```
khideux_Alternant
```

```
khideux_bourse <- chisq.test(TCD_bourse)
```

```
khideux_bourse
```

```
khideux_niveau <- chisq.test(TCD_niveau)
```

```
khideux_niveau
```

```
khideux_Logement <- chisq.test(TCD_Logement)
```

```
khideux_Logement
```

```
khideux_Fumeur <- chisq.test(TCD_Fumeur)
```

```
khideux_Fumeur
```

```
khideux_Alimentation <- chisq.test(TCD_Alimentation)
khideux_Alimentation
```

```
#exo 5
# V de Cramer
n <- dim(df)[1]
p <- nrow(TCD_Sexe)
q <- ncol(TCD_Sexe)
m <- min ( p-1 , q-1)
V_Sexe <- sqrt ( khideux_sexe$statistic / (n*m))
V_Sexe
```

```
n <- dim(df)[1]
p <- nrow(TCD_niveau)
q <- ncol(TCD_niveau)
m <- min ( p-1 , q-1)
V_niveau <- sqrt ( khideux_niveau$statistic / (n*m))
V_niveau
```

```
n <- dim(df)[1]
p <- nrow(TCD_Alternant)
q <- ncol(TCD_Alternant)
m <- min ( p-1 , q-1)
V_Alternant <- sqrt ( khideux_Alternant$statistic / (n*m))
V_Alternant
```

```
n <- dim(df)[1]
p <- nrow(TCD_bourse)
q <- ncol(TCD_bourse)
m <- min ( p-1 , q-1)
V_bourse <- sqrt ( khideux_bourse$statistic / (n*m))
V_bourse
```

```
n <- dim(df)[1]
p <- nrow(TCD_Logement)
q <- ncol(TCD_Logement)
m <- min ( p-1 , q-1)
V_Logement <- sqrt ( khideux_Logement$statistic / (n*m))
V_Logement
```

```
n <- dim(df)[1]
p <- nrow(TCD_Fumeur)
q <- ncol(TCD_Fumeur)
m <- min ( p-1 , q-1)
V_Fumeur <- sqrt ( khideux_Fumeur$statistic / (n*m))
V_Fumeur
```

```
n <- dim(df)[1]
```



```
p <- nrow(TCD_Alimentation)
q <- ncol(TCD_Alimentation)
m <- min ( p-1 , q-1)
V_Alimentation <- sqrt ( khideux_Alimentation$Statistic / (n*m))
V_Alimentation
```